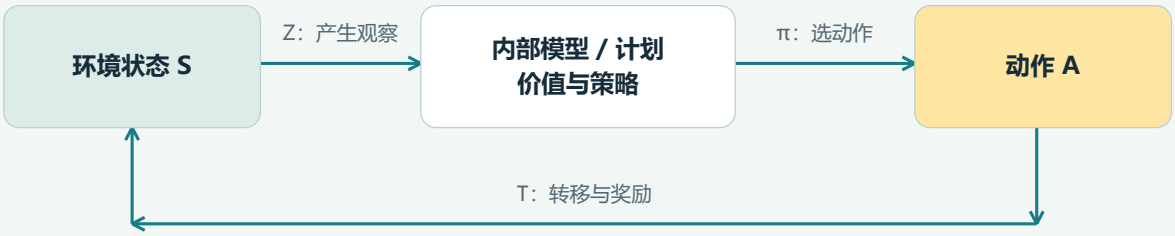
COMP3702

人工智能 • 中文期末复习主册

Understand • Solve • Recall

智能体：观察 → 决策 → 行动

状态描述世界；观察描述智能体能知道什么。



未来决策需要的信息必须保留在状态中，例如位置 + 钥匙 + 电量。

15 个专题 • 10 个算法实验 • 图解、公式与手算示例

从搜索与约束满足，到不确定性规划、强化学习和多智能体博弈。保留英文术语，以中文解释每一步为什么这样算。

配套学习站：双击 study/index.html。训练题和两套自编模拟卷见另一册。先理解，再闭卷手算，最后按评分点纠错。

依据本地 2026 课程资料整理 · 2026-10-24（Brisbane）

最终考试范围以课程公告为准；当前资料没有官方期末样卷，不能保证考试分数。

如何用这份资料复习

本包依据本地 2026 课程讲义与 APP 的 tutorials 制作，日期为 2026-10-24（Brisbane）。目标是覆盖与检验能力，不承诺考试分数。没有获得官方期末样卷或最新考试范围；自编题不能代替官方材料。

每一章都按四遍循环

1. **理解**：读中文讲解，对照原 PDF 页码解释变量和假设。
2. **观察**：在实验室逐步播放，暂停后预测下一步。
3. **闭卷**：在纸上手算，再打开答案按评分点核对。
4. **纠错**：把错误归到模型、公式、代入、顺序、解释中的一种，间隔一天重做。

14 天路线（可按剩余天数压缩）

天	主任务	当天应交出的学习结果
1	智能体、建模、Search 基础	独立写导航和钥匙迷宫模型；做诊断题
2	UCS/GBFS/A*	同一图五种算法的 frontier 表
3	Heuristic / parity	一致性反例、启发式构造、Tutorial 3
4	CSP / AC-3	A<B<C 手算；Tutorial 4.5
5	概率、Markov、MEU	Bayes、矩阵两步、彩票与净利润
6	AND-OR 与 MDP 建模	条件计划；Gridworld 转移表与奖励说明
7	VI	同步 3 轮、policy extraction；比较原地更新
8	PI / RTDP / MCTS	解线性方程；一轮 UCT 与 backup
9	Bandits	ε 概率、softmax、Tutorial 8 UCB
10	MC/TD/Q/SARSA	同轨迹四种 target 与顺序更新
11	Linear VFA / DQN	Pacman 精确权重；DQN 流程图与简答
12	Minimax / Nash	剪枝树、点球混合均衡、Morra 偏离检验
13	Responsible AI；逻辑范围核对	两个案例因果链；完成模拟 A 并评分
14	模拟 B；错题回测	错题二次闭卷通过；速查表主动回忆

7 天压缩路线

第1天建模+Search；第2天CSP+概率+AND-OR；第3天MDP/VI/PI；第4天MCTS+Bandits；第5天RL+VFA+DQN；第6天博弈+Responsible AI+范围核对；第7天两套模拟与错题。时间不足时优先补“做不出的计算过程”，不要只反复阅读熟悉定义。

达标标准（训练建议）

每个核心学习目标至少闭卷做对两道不同题，能用英文关键词写出定义与解释；两套自编卷在自行设定时间内都达到 90/100 以上且错误能复盘；隔 24–48 小时再做错题仍正确。90 分仅是本包的自测门槛，不代表真实考试预测。

文件入口

直接双击 index.html，无需安装、联网或账号。章节、实验、题库和进度均在本机运行；进度记录在当前浏览器的 localStorage。不同浏览器或清理数据后进度可能不同，可导出/导入学习记录。PDF 可打印，Markdown 可编辑。

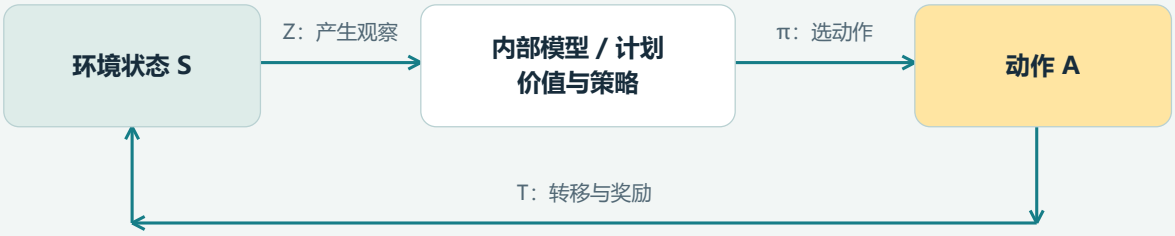
01 • 智能体与建模 / Agents & problem formulation

你要能做到什么

把自然语言题目翻译成可计算的模型，并解释每项假设。如果模型遗漏了影响未来的变量，后面的算法再正确也可能解错问题。

智能体：观察 → 决策 → 行动

状态描述世界；观察描述智能体能知道什么。



未来决策需要的信息必须保留在状态中，例如位置 + 钥匙 + 电量。

六个设计组件

组件	含义	导航例子
S · state space	世界所有可能配置	位置；必要时加入燃油、钥匙、时间
A · action space	每个状态允许的动作	沿某条道路行驶
P/O · percept space	传感器能产生的观察	GPS 读数、可见路况
T · transition	动作如何改变状态	确定的后继，或 P(s′|s,a)
Z · observation	状态如何产生观察	准确位置或带噪 GPS
U · utility	如何评价结果/整段轨迹	负总行驶时间；搜索常写成最小化路径成本

理性（rational）是根据已有信息和资源选择期望表现最好的动作。它不保证实际结果一定最好，也不要求“像人一样思考”。有限算力下使用 MCTS 是 bounded rationality 的例子。

复杂性维度

逐项写出理由：flat/modular/hierarchical；non-planning/finite/indefinite/infinite horizon；state/feature/relation representation；perfect/bounded rationality；given/learned knowledge；fully/partially observable；deterministic/stochastic；goal/complex preference；single/multi-agent；offline/online。

观测不确定性问“我知道自己在哪吗”；**效果不确定性**问“知道现在状态和动作后，能唯一预测下一状态吗”。完全可观测的滑动机器人仍可能是随机系统。静态问环境会不会在思考时改变，和转移是否随机是两件事。

例题：有钥匙的迷宫

状态取 s=(row,col,key_collected)。同一格拿钥匙前后，可用的出口动作和未来回报不同，所以不能合并为同一状态。动作是四方向，撞墙留在原地。若 GPS 精确，则观察可以唯一确定状态；若传感器不报告钥匙，观察空间与完整状态空间不同。

答题模板：**S → A(s) → 初始状态/目标 → T → Z/P → U/成本 → 环境维度与依据。**还要说明动作顺序与一个 time step 的定义。井字棋若一步包含“我方落子+对手回应”，转移模型必须处理对手；若一步只含一个落子，状态应包含轮到谁。

状态、搜索节点与轨迹不是同一个数量

搜索节点通常还记录 parent、action、g。多条路径可以抵达同一状态。井字棋每格三种内容给出 3□=19,683 个配置的上界，许多配置不合法。Tutorial 1 的 255,168 是合法终局**对局序列**的数量，不能当作独立合法棋盘数量。按 X 先手、获胜即停止、旋转反射仍区分的规则，去重枚举可得 5,478 个可达棋盘（本包验证代码附在 scripts 中）。

闭卷自检

为什么位置相同、钥匙不同是不同状态？为什么理性动作也可能输？为什么多条搜索节点路径可以只对应一个世界状态？

原始资料定位

- Module 0 · Introduction，PDF 文件第 45–71 页；lecture/COMP3702_Module-0_IntroToAI.pdf。

- Tutorial 1，PDF 文件第 1–3 页；APP/COMP3702_Tutorial_1(1).pdf。

掌握检验

□ 给新情境写出六个组件并说明环境假设

□ 区分状态、观察、搜索节点与路径

02 • 搜索与启发式 / Search & heuristics

总体结构与考试约定

frontier 存待扩展节点。取出一个节点，做 goal test，再展开后继。explored 通常指已扩展；reached/visited 通常指已生成。**先声明同分规则、后继顺序、判目标时机和重复状态规则**，否则展开顺序可能有多个正确答案。UCS/A* 通常在最小优先级节点出队时接受目标；刚生成目标就停止可能得到次优解。

搜索：同一个图，不同的 frontier 规则

S → A / B → C / D → G；边成本与启发式服务于不同的优先规则。



g：已付成本　h：估计剩余成本　f：完整路径成本估计

路径最少边 ≠ 最低总成本；UCS / A* 通常在目标出队时接受。

算法	取点规则	完备性条件	最优性	典型树搜索复杂度
BFS	FIFO，最浅层	有限分支且解深度有限	等步长成本时最优	时间/空间 O(b□)，本课常用写法
DFS	LIFO，最深	一般不保证；有限图且正确去重时可穷尽	一般不最优	时间 O(b□)，frontier 空间 O(bm)
IDDFS	深度上限 0,1,2,…	有限分支且有限深度解	等步长成本时最优	时间 O(b□)，空间 O(bd)
UCS	最小 g	有限分支，步成本≥ε>0	最低总成本	时间/空间 O(b^(1+□C*/ε□))
GBFS	最小 h	一般不保证；有限图去重可穷尽	一般不最优	最坏可指数，依赖 h
A*	最小 g+h	同 UCS 且合适 h	见下方条件	通常指数；内存常是瓶颈

b 是分支因子，d 是最浅解深度，m 是最大树深，C* 是最优成本。若 BFS 判目标在出队，可能生成下一层，某些教材写 O(b^(d+1))；按题目的伪代码与讲义口径解释即可。DFS 的 O(bm) 不包括额外存整张 visited 表；全图去重可能需要 O(|V|) 内存。有限显式图 BFS/DFS 的另一种计数口径是 O(|V|+|E|)，不要与隐式树的指数口径混用。

可采纳与一致

admissible: 0 ≤ h(n) ≤ h*(n), h(goal)=0
consistent: h(n) ≤ c(n,n′) + h(n′) 对每条有向边
A*: f(n)=g(n)+h(n)

可采纳只比较估计和真实剩余成本；一致性还要求相邻点满足三角不等式。目标 h=0 时，一致 ⇒ 可采纳；反向不成立。

树搜索 A* 用可采纳 h 可保证最优。图搜索若更好路径允许重新打开节点，可采纳通常足够；若 expanded 后永不重开，应要求一致性。**一致性保证首次扩展时的 g 最优，不保证首次生成时 g 最优。**

最优性证明：若返回目标成本 C>C*，最优路径上还应有 frontier 节点 n，满足 f(n)≤C*<C；算法应先取 n，与目标已先被选中矛盾。

一道图题看懂区别

使用交互实验中的有向图：S→A:2，S→B:1，A→C:2，A→G:9，B→C:2，B→D:6，C→G:3，D→G:1。h(S,A,B,C,D,G)=(5,5,4,3,1,0)。目标出队时停止；BFS 生成时去重，DFS 出栈时去重且优先左侧，UCS/GBFS/A* 保留更小 g 并按入队顺序打破优先级平局。

算法	取出顺序（含目标）	返回路径	成本
BFS	S,A,B,C,G	S-A-G	11
DFS	S,A,C,G	S-A-C-G	7
UCS	S,B,A,C,G	S-B-C-G	6
GBFS	S,B,D,G	S-B-D-G	8
A*	S,B,C,G	S-B-C-G	6

A* 展开 S 后 A:(g=2,h=5,f=7)、B:(1,4,5)；先 B，再 C:(3,3,6)，再生成 G:(6,0,6)，最后取 G。**展开顺序和返回路径不是同一列表。**

构造与比较启发式

四邻格最小每步成本 c_min 时，可用 Manhattan×c_min；允许斜走后需重新审查。8-puzzle 的 misplaced tiles / Manhattan 都不计空格，Manhattan 支配 misplaced。放松限制得到更容易问题的最优成本通常是原问题下界。

若 h□,h□ 可采纳，max(h□,h□) 仍可采纳且至少同样有信息；h□+h□ 可能重复计算，不自动可采纳。若 0≤k≤1，kh□ 可采纳；乘以大于 1 的数一般无保证。原始 inversion count 也不能未经证明直接当作 admissible heuristic。

Tutorial 3 的关键反例：h□=h□+5 不可保证可采纳，但若给所有节点（包括目标）都加同一常数，f□=f□+5，优先级排序不变；采用相同正确实现时仍有与原 A* 相同的结果。不要把“非可采纳”误写成“一定不最优”。

2h□ 没有这种保序保证。h□|cos(πh□)|≤h□，因此非负且可采纳；cos(πh□) 会变负或超过真实成本，一般无保证。

8-puzzle parity

按行展平，忽略空格；计算逆序对。3×3 棋盘中合法移动保持逆序对奇偶性；初始与目标 parity 相同才可达。若目标不是标准数字顺序，必须比较双方 parity，或按目标顺序重新编号。偶数宽棋盘还要考虑空格行，不能照搬 3×3 规则。

原始资料定位

- Module 1 · Search，PDF 文件第 20–36, 40–60, 73–89 页；lecture/COMP3702_Module-1_Search.pdf。
- Tutorial 2，PDF 文件第 2–4 页；APP/COMP3702_Tutorial_2(1).pdf。
- Tutorial 3，PDF 文件第 1–3 页；APP/COMP3702_Tutorial_3(1).pdf。

掌握检验

□ 手推 BFS/DFS/UCS/GBFS/A* 的 frontier 和最终路径

□ 检验可采纳、一致性并解释 A* 最优条件

□ 比较复杂度并检查 8-puzzle parity

03 • 约束满足与 AC-3 / Constraint satisfaction

模型先于算法

CSP=(X,D,C)：变量、各变量的域、限制合法组合的谓词。**解**是给所有变量赋值且满足全部约束。填字游戏可把每个词槽作为变量，域为可用单词，长度是一元约束，交叉字母相同是二元约束，单词不得复用可写 all-different。

Backtracking 每次固定一个变量，只要当前可判断的约束冲突就回溯。若 d 个值、n 个变量，最坏 d^n 个完整赋值；相比无视冲突直到末尾的 generate-and-test，能提前剪掉整棵子树。

三种检查

方法	做什么	不保证什么
Domain/node consistency	删掉违反一元约束的值	不检查跨变量组合
Forward checking	新赋值 X=x 后删邻居不兼容的值	不反复传播未赋值邻居间的影响
Arc consistency	对每条有向弧反复保证每个值有支持	一般不能证明全局有解

弧一致：每个值都必须找到支持

X → Y 检查 X 的值；删除 X 后，可能影响邻居 Z → X 的支持。



x=1 可由 y=2 支持；x=2 可由 y=3 支持；x=3 无支持。

局部都有支持，仍不代表所有约束能同时满足。

X→Y consistent ⇔ □x∈D(X), □y∈D(Y): C(X=x,Y=y)

这句里的 □ 和 □ 最容易考错。支持可以对不同 x 选择不同 y，并不是找一个 y 支持所有 x。

AC-3 伪代码

```
queue = all_directed_arcs()
while queue:
    X, Y = queue.pop(0)
    if revise(X, Y):        # 只删除 D(X) 中无支持的值
        if not D[X]:
            return FAILURE
        for Z in neighbours[X] - {Y}:
            queue.append((Z, X))
return DOMAINS
```

删除 X 的值后要复查 **Z→X**，因为原来依赖被删 x 的 Z 值可能失去支持。不是只查 X→Z。实现时保存域快照；回溯离开分支后必须恢复删掉的值。

手算：A<B<C

初始 D(A)=D(B)=D(C)={1,2,3}。一种合法队列过程：

1. A→B：A=3 无 B>3，删 3，A={1,2}。

2. B→A：B=1 无 A<1，删 1，B={2,3}。

3. B→C：B=3 无 C>3，删 3，B={2}；重新加入 A→B。

4. C→B：只有 C=3 支持 B=2，删 C=1,2。

5. A→B：只有 A=1 支持 B=2，删 A=2。

6. 队列耗尽，唯一解 (1,2,3)。交互实验逐弧展示域变化。

最终域不依赖合法处理顺序，但中间过程和检查次数依赖顺序。题目若要数次数，必须遵循给定队列策略。

AC 完成后的三种结局

出现空域 ∅ 无解；所有域均为单值且网络约束已一致 ∅ 得到解；仍有多值 ∅ 可能有解也可能无解，需要继续搜索。反例：三角形三顶点只用两种颜色，任意相邻顶点不等。每个值都有邻居支持，所以 arc-consistent，但整体无解。

搜索顺序与复杂度

MRV：先选剩余合法值最少的变量；degree 可用于打破平局。LCV：对选中变量优先尝试使邻居删值最少的值。前者希望尽早暴露失败，后者希望保留未来选择。

二元 AC-3 常见最坏时间 $O(ed^3)$，空间 $O(e+nd)$，e 是弧/约束数量的量级，d 是最大域大小；稠密图 $e=O(n^2)$ 时写 $O(n^2d^3)$。数值域连续或高元约束不能不加说明套这个界。

Tutorial 4.5 答题检查

由 A>3、F∈{5,6}、A>F 得 A=6、F=5；由 |A−B|=2 且 B 偶数得 B=4。再结合 all-different、D<A、E∈{1,6}、|E−C|=1 可取 (A,B,C,D,E,F)=(6,4,1,3,2,5)。先区分“经过一元约束后的域”“AC 后的域”和“最终一个解”，不能提前把某个解当成所有可能值。

原始资料定位

- Module 2 · CSP，PDF 文件第 9–42 页；lecture/COMP3702_Module-2_CSPs_2026(1).pdf。
- Tutorial 4，PDF 文件第 1–3 页；APP/COMP3702_Tutorial_4(1).pdf。

掌握检验

□ 把填字/排班题写成 CSP

□ 逐弧执行 AC-3 并记录删值和重入队

□ 解释 AC 无法保证有解与 MRV/LCV 的作用

04 • 概率、Markov 链与决策理论 / Probability & expected utility

必会概率公式

$$P(A|B)=P(A\cap B)/P(B),\ P(B)>0$$
$$P(A\cup B)=P(A)+P(B)-P(A\cap B)$$
$$P(A\cap B)=P(A)P(B|A)=P(B)P(A|B)$$
$$P(A|B)=P(B|A)P(A)\ /\ \Sigma_{\square}\ P(B|A_{\square})P(A_{\square})$$
$$E[X]=\Sigma_{\square}\ xP(X=x)$$

互斥（mutually exclusive）表示不能同时发生；独立（independent）表示知道一个不会改变另一个的概率。两个概率都大于零的互斥事件不会独立。

PMF 对离散值求和为 1；PDF 对区间积分才是概率，密度值可大于 1，连续变量单点概率为 0。CDF $F(x)=P(X\le x)$。抽样时固定 seed 有助复现，不会使样本分布必然正确或样本之间自动独立。

Bayes 手算

设事件 H 的先验 P(H)=0.1，P(E|H)=0.8，P(E|¬H)=0.2。则 P(E)=0.8×0.1+0.2×0.9=0.26，P(H|E)=0.08/0.26=4/13≈0.3077。**0.8 是似然，不能直接当后验。**

Markov 链

Markov property：给定当前状态后，下一状态的条件分布无需完整历史。转移矩阵 P 的行是当前状态，列是下一状态，每行非负且和为 1。行向量分布 x□ 满足 x□□□=x□P，因此 x□=x□P□。

Tutorial 5 的三状态例子：

```
P=[[.5,.5,0],[.2,.5,.3],[0,.5,.5]]
x□=[0,0,1] → x□=[0,.5,.5] → x□=[.1,.5,.4]
stationary: xP=x, Σx□=1 → x=[.2,.5,.3]
```

有限链不可约且非周期时，从任意初始分布迭代会收敛到唯一平稳分布。周期链可能有平稳分布，但 x□P□ 不收敛；例如两个状态确定来回跳。教程六格反射随机游走的平稳分布为每格 1/6。

决策理论：先定义效用，再求期望

MEU：a*=argmax□ Σ□P(o|a)U(o)。期望金钱只在以金钱线性定义效用时等于期望效用。风险厌恶常用凹效用，风险偏好常用凸效用；不能把 U(E[X]) 与 E[U(X)] 混同。

理性偏好公理：completeness（可比较）、transitivity（传递）、monotonicity（好结果概率更高更优）、continuity（中间结果可与两端彩票无差异）、substitutability（无差异项可替换）、decomposability（复合彩票按概率展开）。例如 [0.4:A,0.6:[0.5:B,0.5:C]] 等价 [0.4:A,0.3:B,0.3:C]。

讲义二手车：好车效用 60，坏车 −100，坏车概率 0.2，买车 EU=0.8×60−0.2×100=28，比不买 0 高。坏车概率为 p 时买车净期望 60−160p，临界 p=0.375。

Tutorial 5 租车：统一“第一年净利润”口径，把购买成本也算入。5 辆 GenCar 为 42,250；2 辆 Tesla 为 −725；改装 Tesla 为 8,775，因此选 GenCar。不能只比较每天租金或只比较最好情景。

折扣回报

```
G□=R□□□+γR□□□+γ²R□□□+… = R□□□+γG□□□
恒定每步回报 r，0≤γ<1：G=r/(1−γ)
若 |R|≤Rmax，忽略前 k 步之后的尾部，误差≤γ□Rmax/(1−γ)
```

例：[2,0,10]，γ=0.9，回报为 2+0+0.81×10=10.1。不要把第一笔即时回报也乘 γ。γ=1 的终止任务可有有限回报，但无限期有正奖励的循环不再有有限折扣值。

原始资料定位

- Week 6 · Probability / AND-OR / Decision Theory，PDF 文件第 12–25, 45–69 页；lecture/COMP3702_Module-3-Part1_Wk6_Probability_AND-ORTrees_DecisionTheory(1).pdf。

- Tutorial 5 · Solutions，PDF 文件第 1–3, 5–6 页；APP/COMP3702_Tutorial_5_soln.pdf。

掌握检验

□ 计算 Bayes、全概率与期望效用

□ 写出转移矩阵并计算多步/平稳分布

□ 计算折扣回报并解释偏好公理

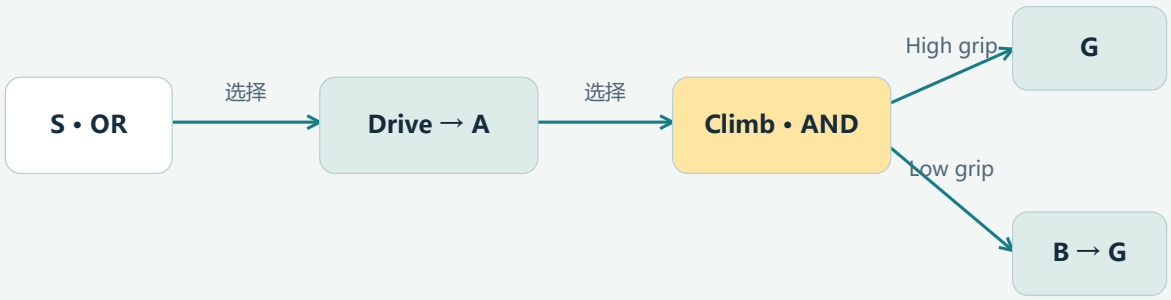
05 • 非确定性与条件计划 / AND-OR search

为什么固定动作序列不够

确定性搜索输出一条路径；动作可能有多个结果时，计划需要根据实际观察选择后续动作。解通常是**条件计划/策略子树。**

条件计划：选一个动作，覆盖全部结果

Tutorial 5 的 Safe Drive / Climb / Bridge。



Risky Jump 的 DEAD 分支使其失败；不能只保留那个能到 G 的结果。

OR 状态节点：由 agent 选择动作，有一个 solved 动作就 solved。AND 动作节点：由环境产生结果，所有可能结果都可解决才 solved。目标 solved；不可恢复死路 closed；尚未展开或证明的节点可以是 unsolved，不能直接当失败。

Tutorial 5.2 的完整逻辑

S 有 Safe Drive→A 和 Risky Jump→{G,DEAD}。A 有 Scan→A 和 Climb→{G,B}。B 有 Bridge→G。

1. G solved，DEAD closed。

2. Jump 有 DEAD 结果，所以 AND 节点 closed，虽然另一个结果直接到 G。

3. Bridge solved，所以 B solved。

4. Climb 的 G 与 B 都 solved，所以 Climb solved，A solved。

5. Safe Drive solved，因此 S solved。

得到：**Drive；Climb；若到 B 则 Bridge；若到 G 则结束。** 这个计划包含 Climb 的全部结果分支，只保留 S、A 各一个选定动作。

循环必须说明成功定义

若采用无环强计划，搜索路径中重复祖先状态可关闭该分支。某些允许循环的计划会“只要没成功就重试”：这需要公平性或每次有适当成功概率等额外条件。不能因为存在概率成功的出口就宣称对任意环境结果序列保证有限步成功；也不能说所有循环一定无解。

AND-OR、Expectimax、Minimax 的关系

环境/目标	动作/决策层	结果层
强可达计划	OR：至少一个动作成功	AND：所有结果可达目标
已知概率的 MDP	max 期望回报	按概率加权求和
零和理性对手	minimax 的 MAX	minimax 的 MIN，取最坏情况

计算概率题时不能把平均值换成 min；对手模型题也不能假设对手随机均匀。

原始资料定位

- Week 6 · Probability / AND-OR / Decision Theory，PDF 文件第 28–42 页；lecture/COMP3702_Module-3-Part1_Wk6_Probability_AND-ORTrees_DecisionTheory(1).pdf。

- Tutorial 5 · Solutions，PDF 文件第 3–5 页；APP/COMP3702_Tutorial_5_soln.pdf。

掌握检验

□ 给 AND-OR 树逐层标 solved/closed 并提取条件计划

□ 区分强计划、循环计划、期望与最坏情景

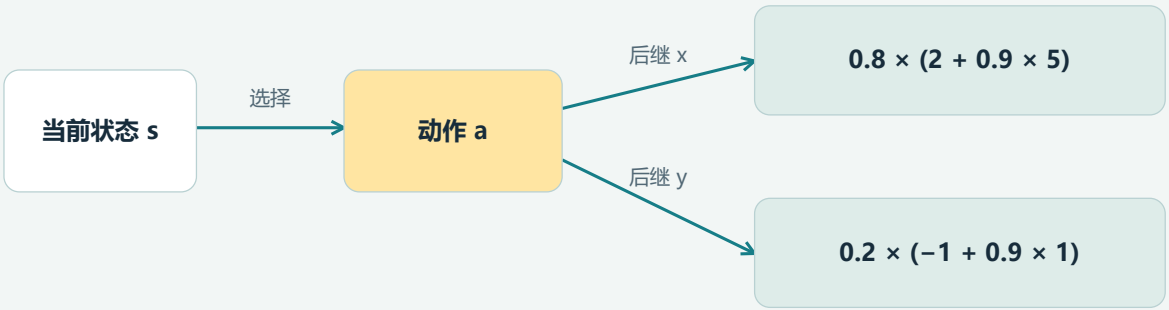
06 • MDP、价值迭代与策略迭代 / Markov decision processes

MDP 的输入与输出

MDP=(S,A,T,R,γ)，可另给初始状态 s□。状态完全可观测，动作影响随机转移，满足 Markov property。输出是状态到动作的策略 π，而非仅一条起点到终点路线。有限时域常需要时间相关 π□(s)，把剩余时间纳入状态也可表达；deterministic 和 stationary 是不同性质。

Bellman：先算结果期望，再比较动作

Q = 一步奖励 + 折扣后的未来价值；V 是最大 Q，策略是 argmax。



Q(s,a)=5.18；若动作 b 的 Q=4，则 V(s)=5.18，π(s)=a。

V、Q、R、π 各是什么

$$V^\pi(s)=E^\pi[G_t \mid S_t=s]$$
$$Q^\pi(s,a)=\sum_{s'} T(s,a,s')[R(s,a,s')+\gamma V^\pi(s')]$$
$$V^\pi(s)=\sum_a \pi(a \mid s)Q^\pi(s,a) \quad \text{（确定性策略时取指定动作）}$$
$$Q^*(s,a)=\sum_{s'} T(s,a,s')[R(s,a,s')+\gamma V^*(s')]$$
$$V^*(s)=\max_a Q^*(s,a),\quad \pi^*(s)\in \arg\max_a Q^*(s,a)$$

R 是单步回报；V 是从状态开始的预期总折扣回报；Q 是先做某动作再继续的总回报；π 返回动作（或分布）。max 返回数值，argmax 返回取得最大值的动作。

Bellman 手算模板

动作 a：0.8 到 x，奖励 2，V(x)=5；0.2 到 y，奖励 −1，V(y)=1。γ=.9。

$$Q(s,a)=.8(2+.9\times5)+.2(-1+.9\times1)=5.18$$

若动作 b 确定得到 4 并终止，Q(s,b)=4，因此 V 新值 5.18，策略选 a。每个分支都先计算 R+γV，再乘分支概率，再相加；最后才跨动作取 max。

VI：同步手算

从 $V_0=0$ 开始，每轮所有状态仅使用上一轮 V_k。

$$V_{k+1}(s)=\max_a \sum_{s'} T(s,a,s')[R(s,a,s')+\gamma V_k(s')]$$
$$\Delta=\max_s |V_{k+1}(s)-V_k(s)|$$

例：B 的 exit 动作获 10 到 E；A→B 奖励 0；A 也可直接获 4 到 E；E 吸收且奖励 0。γ=.9。

k	A	B	E
0	0	0	0
1	4	10	0
2	9	10	0
3	9	10	0

注意 $V_0(A)=4$，但用 V_0 提取下一步策略时已会选去 B（比较 9 与 4）。**哪轮 value 对应哪次提取的 policy，要写清定义。**原地更新在同轮使用最新值，数表会不同；题目没允许时不要混用。

γ<1、有界奖励时 Bellman 最优算子是 γ-contraction，故 VI 收敛到唯一 V^*。可用 Δ 作为停止标准；若 $\Delta=\|V_{k+1}-V_k\|_\infty$，则 $\|V_{k+1}-V^*\|_\infty \le \gamma\Delta/(1-\gamma)$。策略可能在价值完全收敛前已正确，但仅看到几个动作不变不能普遍证明最优。

PI：评估与改进分开

固定 π 后不取 max：

$$V^\pi=r^\pi+\gamma P^\pi V^\pi$$
$$(I-\gamma P^\pi)V^\pi=r^\pi$$
$$r^\pi(s)=\sum_{s'} T(s,\pi(s),s')R(s,\pi(s),s')$$
$$\pi_{new}(s)\in \arg\max_a \sum_{s'} T(s,a,s')[R(s,a,s')+\gamma V^\pi(s')]$$

小例：策略在 A 选“每步奖励 1 并留 A”，γ=.9，所以 Vπ(A)=1+.9Vπ(A)=10。另一个动作 exit 得 12，所以改进为 exit，重新评估 V=12。若所有状态都不能严格改进，策略稳定并最优。平局时保留旧动作避免无意义来回切换。

一般 rπ 是按转移平均后的即时奖励，不一定是一个与动作无关的 r(s)。代码优先解线性系统而非显式算逆。

算法	一轮做什么	稠密转移典型单轮时间	需要已知模型
VI	每状态比较所有动作	O(|S|²|A|)	是
PI	固定策略评估+贪心改进	O(|S|³+|S|²|A|)	是
Modified PI	有限次评估+改进	依评估次数与表示而定	是

PI 往往轮数少但单轮更贵；“总是更快”不成立。确定性平稳策略数量最多 \|A\|^\|S\|，不是 \|A\|×\|S\|。GPI 指策略评估与策略改进相互作用的总体框架。

Gridworld 的三个大坑

1. 撞墙/障碍留在原格时，多种方向结果可能到同一状态，概率要**相加**，每个 (s,a) 的概率和仍为 1。例如左上角执行 Up：Up .8 与 Left .1 都撞墙，留原地 .9，Right .1。

2. Tutorial 6/8 有钥匙，状态应带 key。教学实验为了突出 VI，使用 Tutorial 7 风格无钥匙简化版，并明确标注，不能冒充带钥匙题的结果。

3. 奖励时点：本包格子实验进入彩色格奖励 0，在格子执行 exit 才得 +1/−1，到 exited 后 0。于是 V(彩色格)=奖励，V(exited)=0。从邻格移动到彩色格会多乘一次 γ。若题目规定进入终点立即给奖励，则终点 V=0，用另一套模型；两者都可自洽，但不能混在一道题里。

Tutorial 5.4 的约定为 exit 发奖：向右 V(s□,s□,s□,s□)=(10γ⁴p²,10γ³p²,10γ²p²,10γp)。向左对应 (5γ,5γ²,5γ³p,5γ⁴p²)。γ=.9,p=.8 时 s□ 向右=4.6656，向左=4.05，故两者相比右更好。

原始资料定位

- Week 7 · MDP / VI / PI，PDF 文件第 11–58 页；lecture/COMP3702_Module-3-Part2_Wk7_MDPs_VI_PI(1).pdf。

- Week 8 · PI / RTDP / MCTS，PDF 文件第 15–33 页；lecture/COMP3702_Module-3-Part2_Wk8_MDPs_PI_QLearning.pdf。

- Tutorial 6，PDF 文件第 1–3 页；APP/COMP3702_Tutorial_6.pdf。

- Tutorial 5 · Solutions，PDF 文件第 7–8 页；APP/COMP3702_Tutorial_5_soln.pdf。

掌握检验

□ 从自然语言构造 MDP 并统一奖励时点

□ 手算同步 VI、策略提取与 PI 线性方程

□ 比较 VI/PI 并正确累加碰撞概率

07 · 在线规划、RTDP 与 MCTS / Online planning & sampling

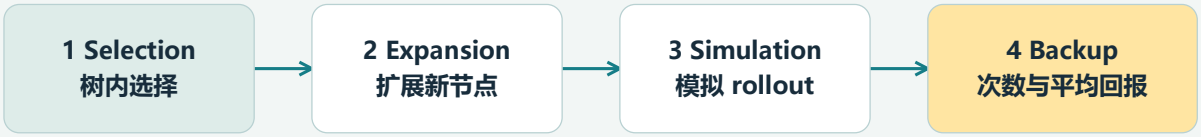
从全状态离线计算到当前状态决策

VI/PI 一般为整个状态空间求策略，大空间可能无法存储或计算。在线规划在当前状态分配有限预算，决定一个动作后再规划。它并不等于 model-free；MCTS 可以使用模拟器进行 model-based planning。

RTDP 从起点模拟轨迹，按当前价值贪心选择动作，只对访问状态执行 Bellman backup，然后从转移模型采样下一状态。它把计算集中在相关区域；最优收敛依赖访问覆盖、初始化等条件，不能把“只走一条贪心路径”理解为无条件保证最优。

MCTS：四步反复，预算用完再执行动作

树内探索分数 UCB，与最终推荐动作的规则要分清。



Qnew = Qold + (G − Qold) / Nnew

模拟更多次通常改进估计；有限预算并不保证最优。

四个阶段

1. **Selection**：在已有树中按 tree policy（常用 UCB/UCT）向下选择，平衡利用和探索。

2. **Expansion**：在可扩展的非终止节点加入未展开动作/后继。真正的终止节点不再展开。

3. **Simulation / Rollout**：从新节点用默认策略和模拟器得到一条到终止或截断深度的回报。

4. **Backpropagation / Backup**：沿访问路径逆向更新计数和均值；随机 MDP 中按所选路径的折扣回报更新，不能把所有机会结果一律取最大。

UCT(s,a)=Q□(s,a)+c√[ln N(s)/N(s,a)]
Nnew=Nold+1
Q□new=Q□old+(G−Q□old)/Nnew

未访问动作优先尝试或把其分数视为 +∞，避免除以零。Q□ 是平均回报，N(s) 是节点访问数，N(s,a) 是动作次数。c 越大越偏探索。树内用于探索的 UCB 决策，和预算用尽时返回根动作的规则不是同一件事；后者可按均值或访问数，需按题目规定。

一次 backup 例题

某边有 N=3、均值 Q□=2；新 rollout 从该边出发的回报 G=6。新计数 4，新均值 2+(6−2)/4=3。若这条边上方一步奖励为 1 且 γ=.9，上方边应接收 G_parent=1+.9×6=6.4，不是简单复制 6。

你应能比较

MCTS 只需 generative simulator，不一定需要完整转移概率表；它的 rollout 不是在真实环境反复执行危险动作。anytime 表示预算中断后能返回当前建议，**不表示有限预算下必然最优**。更长 rollout 也不自动解决偏差，结果受 rollout 策略、分支因子和预算影响。

课程提供的 mcts.py 适合作阅读练习，但学习统计更新时请统一旧计数/新计数：如果先增加 N，再用 (Q×N+G)/(N+1)，会把计数用错。本包采用上面的增量均值式，并通过数值检查。

原始资料定位

- Week 8 · PI / RTDP / MCTS，PDF 文件第 34–55 页；lecture/COMP3702_Module-3-Part2_Wk8_MDPs_PI_QLearning.pdf。

- Tutorial 7，PDF 文件第 1–2 页；APP/COMP3702_Tutorial_7.pdf。

掌握检验

□ 按顺序解释 MCTS 四步和 UCT 各项

□ 手算计数、均值与折扣 backup

□ 区分在线规划、模型学习和 model-free RL

08 • 探索与利用：多臂老虎机 / Multi-armed bandits

Bandit 与 MDP 的区别

普通平稳 bandit 每次选择一个臂，观察该臂回报；不建模会影响未来状态的长程转移。目标是最大累计回报，不能只追求最终识别出最好臂。探索能改进估计，却牺牲当前可能获得的奖励。

```
Qnew(a)=Qold(a)+(r−Qold(a))/Nnew(a)
pseudo-regret(T)=Σ□[μ*−μ(a□)]
```

样本平均的学习率为 1/N；固定 α 对新数据权重更高，可适应非平稳情况，但不再等于全历史均值。

ε-greedy

概率 ε 从全部 k 个动作均匀随机选，概率 1−ε 选择当前贪心动作。若唯一最大：P(best)=1−ε+ε/k，其他每个 ε/k。k=4、ε=.2 时为 .85 和 .05。若 g 个动作并列最大且贪心时均匀打破平局，每个最大动作概率 (1−ε)/g+ε/k。

ε-decay 随时间减少探索，但下降太快可能过早锁定错误动作；指数衰减本身不保证无限探索。GLIE 同时要求极限趋于贪心与对必要状态动作持续充分探索。

Softmax

```
P(a)=exp(Q(a)/τ)/Σ□ exp(Q(b)/τ), τ>0
```

τ 越高越接近均匀，τ→0 偏向最大 Q（并列时在最大项间分配）。τ=1 时仍需归一化，不能直接写概率=e^Q。所有 Q 加同一常数不改变概率；实现减去最大 logit 可防止溢出。

UCB：题目公式优先

讲义：Q(a)+C√(ln N/n□)；Tutorial 8：Q(a)+√(C ln N/n□)。两者通过 C_inside=C_outside² 对应，**不能带相同数值 C 当成相同公式。**探索奖励随 n□ 增大缩小，固定 n□ 时随总 N 增大变大；从未拉过的臂应先试。

Tutorial 8.1 的计算

A□ 回报 2.66,3.21,1.87,1.69，总 9.43、次数 4，均值 2.3575。A□ 回报 1.25,2.34，总 3.59、次数 2，均值 1.795。

ε-greedy 的利用部分选 A□；若 ε<1，A□ 更可能。按题目 C=5 在根号内，N=6：

```
UCB□=2.3575+√(5ln6/4)≈3.8541
UCB□=1.7950+√(5ln6/2)≈3.9115 → 选 A□
```

均值较低的臂仍可因不确定性更大被选择。实验室可观察样本均值、次数、累计回报与 pseudo-regret；单次随机运行不能证明某算法普遍更好。

题目给 Weibull shape=2、scale=2√2 时，均值 scale×Γ(1+1/shape)=√(2π)≈2.5066，小于 A□ 的 3；若分布已知且目标是期望累计回报，应一直选 A□。这是补充推导，不要求背通用 Weibull 密度式。

原始资料定位

- Week 9 · MAB / RL，PDF 文件第 19–31 页；lecture/COMP3702_Module-4-2026_Wk9(1).pdf。

- Tutorial 8，PDF 文件第 1–2 页；APP/COMP3702_Tutorial_8.pdf。

掌握检验

□ 算 ε-greedy/softmax 概率

□ 按题目参数化手算 UCB 并解释探索项

□ 说明探索衰减与样本平均的限制

09 • MC、TD、Q-learning 与 SARSA / Tabular reinforcement learning

四条分类轴

Model-based：学习/使用 T、R，再规划；model-free：直接学 V、Q 或 π。Passive：评估固定策略；active：学习如何选择动作。On-policy：学当前行为策略；off-policy：目标策略和行为策略可以不同。Online 与 offline 是另一条轴，不能互相替代。

模型估计可用 T□(s,a,s′)=count(s,a,s′)/count(s,a)；随机奖励 R□(s,a,s′) 应是相关观测奖励均值，不应默认最后一次奖励就是精确模型。

同一经验 (s,a,r,s′)，不同的学习目标

更新统一为 estimate ← estimate + α × (target − estimate)。

MC	TD(0)	Q-learning	SARSA
实际整幕回报 G	r + γV(s′)	r + γ max Q′	r + γQ(s′,a′)

Q-learning：贪心目标策略；SARSA：实际执行的下一个动作。

真正终止后继的未来价值 = 0，因此 target = r。

所有更新都围绕 target − current

算法	目标 target	需要等整幕结束	Bootstrap	学什么
MC policy evaluation	真实采样回报 G□	通常需要	否	Vπ
TD(0)	r+γV(s′)	否	是	Vπ
Q-learning	r+γmax□′Q(s′,a′)	否	是	Q*，off-policy
SARSA	r+γQ(s′,a′)，a′ 为实际下一个动作	否	是	Qπ，on-policy

```
estimate ← estimate + α(target−estimate)
TD error δ=target−current
terminal successor: target=r （不再加下一状态价值）
```

MC 的“真实回报”指这一条轨迹实际采到的回报，不等于真实期望 Vπ。First-visit MC 每幕每个状态只更新首次访问对应回报；every-visit MC 更新每次访问。用 1/N 作平均时先把 N 从 0 增为 1，再除以 N。

对照算例

Q(s,a)=3，r=2，γ=.9，α=.5；下一状态 Q 值为 [8,1]，实际执行第二个动作。

```
Q-learning target=2+.9×8=9.2
Qnew=3+.5(9.2−3)=6.1
SARSA target=2+.9×1=2.9
Qnew=3+.5(2.9−3)=2.95
```

行为动作即使是探索选的低 Q 动作，Q-learning 仍用 max；SARSA 必须使用那个实际 a′。若 s′ 已终止，两者 target 都是 2，更新后都为 2.5。

MC 与 TD 对同一状态的差异

轨迹 A --2→ B --0→ C --10→ terminal，γ=.9，V(B)=5，V(A)=0，α=.5。 MC 的 A target 为 10.1，V(A) 更新为 5.05；TD(0) target=2+.9×5=6.5，更新为 3.25。MC 回报常方差较大，TD 的 bootstrap target 受现有估计影响；不能说某一方法无条件更准确。

Tutorial 8 的 chain Q-learning

7 个状态，目标 4，每个非目标动作 −1；目标动作 0 并结束，γ=1。最优 V*(s)=−|s−4|。 Q 初始全 0、α=.5，按顺序仅重放一次：

(3,−1,−1,2): Q(3,−1)=−.5
(2,+1,−1,3): max Q(3,·)=max(−.5,0)=0 → Q(2,+1)=−.5
(3,+1,−1,4): Q(3,+1)=−.5
(4,+1,0,terminal): Q(4,+1)=0

不能拿未执行动作也已变为 −.5，更不能用最终表回头重算第一条。初始 0 在负奖励环境里是乐观估计，未探索动作会显得更好。

SARSA 为什么可能绕开悬崖

训练时 ε-greedy 会偶尔随机行动。SARSA 的目标反映这些探索动作的风险，可能偏好更安全路径；Q-learning 学习贪心目标策略的价值，可能沿悬崖附近。比较的是所学目标与行为，不是“SARSA 一定风险厌恶”的通用定理。

收敛条件要写完整

有限表格情形，适当折扣/终止条件、奖励有界、每个必要 (s,a) 无限访问、每对学习率满足 Σα=∞ 且 Σα²<∞，是标准 Q-learning 收敛条件。固定 α=.5 和有限训练次数只是演示，不保证精确收敛。加入函数逼近后不能直接沿用表格收敛保证。

n-step 补充辨析

G□^(n)=R□□□+γR□□□+…+γ^n□¹R□□□+γ^nV(S□□□)

n 是 bootstrap 前真实采样的步数，1-step TD 即 TD(0)。讲义 Week 10 PDF p16 用 TD(λ) 字样描述多步数时容易与标准 eligibility-trace TD(λ) 混淆；这里将其称为 n-step TD。标准 λ 是混合不同步长回报的参数，不是整数步数。

原始资料定位

- Week 9 · MAB / RL，PDF 文件第 32–55 页；lecture/COMP3702_Module-4-2026_Wk9(1).pdf。

- Week 10 · MC / TD / Approximation / ML，PDF 文件第 10–25 页；lecture/COMP3702_Module-4-2026_Wk10.pdf。

- Tutorial 8，PDF 文件第 2–4 页；APP/COMP3702_Tutorial_8.pdf。

- Tutorial 9，PDF 文件第 1 页；APP/COMP3702_Tutorial_9(1).pdf。

掌握检验

□ 给经验序列逐条更新 Q-learning 和 SARSA

□ 计算 MC/TD target 并处理终止状态

□ 区分四条分类轴和表格收敛条件

10 • 特征与线性函数逼近 / Value function approximation

为什么不一直用表

连续或巨大状态空间无法给每个 (s,a) 存一格。函数逼近用共享参数把相似状态联系起来。

$Q_w(s,a;w)=\Sigma_i w_i f_i(s,a)$，$f_0=1$ 可表示 bias
$\delta=r+\gamma\max_{a'}Q_w(s',a';w)-Q_w(s,a;w)$
$w_i \leftarrow w_i + \alpha\delta f_i(s,a)$

这是 Q-learning 的线性半梯度更新。先用**旧权重**计算整个 δ，再更新全部权重；不要更新一个权重后用变化的 Q 重算后面的 δ。每动作独立权重和带动作编码的联合特征都是可行表示，题目必须说清参数共享方式。

Tutorial 9.2 精确算例

当前 Q=4f_food−1f_ghost，特征 (.5,1)，因此 Q=1。下一状态终止，r=−500，α=1/250=.004。

$\delta=-500-1=-501$
$w_{food}=4+.004\times(-501)\times.5=2.998$
$w_{ghost}=-1+.004\times(-501)\times1=-3.004$
new $Q(s,a)=2.998\times.5-3.004=-1.505$

参考答案约写为 (3,−3)，本包保留精确值。负的 ghost 权重绝对值更大，使接近鬼的动作评价更差；不是“权重变得更正”。

泛化的收益与代价

收益：参数更少、共享经验、能评价未访问状态、适用于连续状态。代价：需要有用特征，模型表达能力有限，错误特征会把不同风险的状态合并。线性 Q 不意味着奖励必须线性；真正限制的是所表示的价值函数形状。

若用 $Q_w(x,y,a)=w_0+w_1x+w_2y$，它无法随意表示墙另一边突然变差的复杂非线性风险；“离目标的几何距离”也可能无法反映障碍。

与梯度下降的关系

一般近似器使用 $w\leftarrow w+\alpha\delta\nabla_w Q_w(s,a;w)$。在线性情形 $\nabla_w Q_w=f$，所以回到 αδf。监督学习最小化损失时写 $w\leftarrow w-\alpha\nabla L$；符号不同来自 δ=target−prediction，两个写法不矛盾。

讲义把详细 SGD 推导标为 OPTIONAL（Week 10 PDF p49–52），重点仍是理解特征、手算 δ、更新权重和解释泛化限制。

原始资料定位

- Week 10 · MC / TD / Approximation / ML，PDF 文件第 31–50 页；lecture/COMP3702_Module-4-2026_Wk10.pdf。

- Tutorial 9，PDF 文件第 1 页；APP/COMP3702_Tutorial_9(1).pdf。

- Tutorial 9 · Solutions，PDF 文件第 1–2 页；APP/COMP3702_Tutorial_9_soln(1).pdf。

掌握检验

□ 根据特征手算 Q、δ 和全部权重的新值

□ 解释参数共享、泛化与表达能力限制

11 • 神经网络、DQN 与策略梯度 / Deep reinforcement learning

神经网络需要理解到哪一层

ML 从数据学习规律；DL 是利用多层神经网络学习表示的一类 ML。监督学习有输入标签，非监督学习找数据结构，RL 从交互和奖励学习决策。单元计算 y=g(b+Σw□x□)，非线性激活使多层网络能表达超出线性函数的关系；若所有层都线性，层数再多仍只是一个仿射变换。

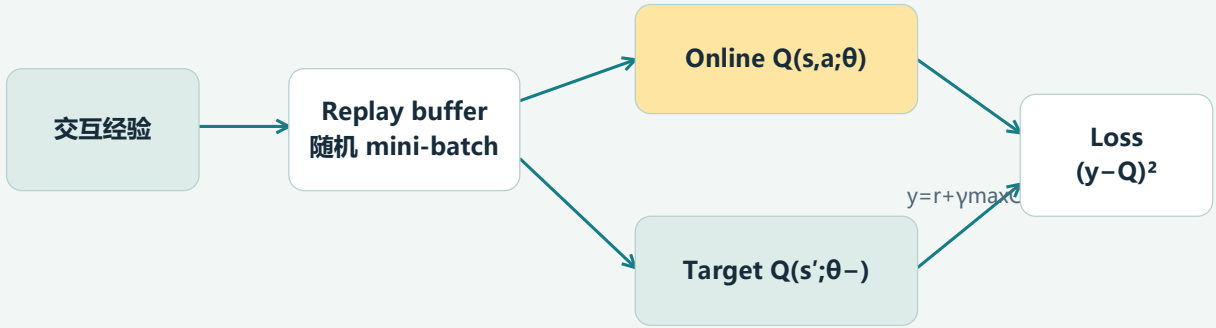
训练：前向预测 → 计算损失 → 反向传播求梯度 → 优化器更新参数。网络权重是 parameters，层数、学习率、batch size 等是 hyperparameters。训练误差小不等于泛化好，要在未见数据/环境评估。

DQN 用网络替代表格

通常输入状态 s，一次输出离散动作对应的一组 Q(s,a;θ)，例如 CartPole 4 维状态 → 2 个 Q 输出。连续的是 Q 数值；离散的是输出对应的**动作集合**。不能说“DQN 输出只能取离散数值”。

DQN：经验池复用样本，目标网络稳定目标

当前网络预测 Q(s,a;θ)，目标网络只用于构造 y。



只优化 Online 参数；周期复制或软更新 Target 参数。终止时 y=r。

$$y=r+\gamma(1-done)\max_{a'}Q(s',a';\theta_target)$$
$$L(\theta)=mean[(y-Q(s,a;\theta))^2]$$
$$\theta \leftarrow \theta-\alpha\nabla_{\theta}L$$

一次训练只监督这条经验实际采取动作 a 对应的 Q 输出，其他输出不直接指定新 TD target，但共享网络权重仍可能令它们变化。

两个稳定训练的关键

Experience replay：存储 (s,a,r,s′,done)，随机采样 mini-batches，减少连续样本相关性并复用经验。不能保证绝对独立或彻底消除过拟合。

Target network：用固定/缓慢更新的 θ_target 计算 y，减少目标随着当前网络同步剧烈变化造成的不稳定。硬更新每 K 步复制一次；软更新 θ_target←τθ+(1−τ)θ_target。target 不在本次损失中反向求导。

例：Q(s,a)=2，r=1，γ=.9，目标网络在 s′ 的输出 [3,5]，非终止，则 y=5.5，平方误差=12.25。若已终止，y=1，平方误差=1。

常见技巧与边界

Reward clipping 可稳定跨游戏尺度，但会改变原奖励优化目标；frame skipping 减少计算；多帧状态有助估计速度。Double DQN 用当前网络选择下一动作、目标网络估值以减轻 max 高估；Dueling 用 V 与 advantage 表示 Q，这些了解动机即可，不自行扩大成推导必考点。

Policy Gradient

直接参数化 πθ(a|s)，增加高回报动作的概率，可用连续分布建模连续动作。经典 REINFORCE 的概念式：θ←θ+αG□□θ log πθ(a□|s□)。这是理解式补充，课程重点是“直接学策略”与 DQN“学 Q 再 argmax”的区别；并非所有策略梯度家族成员都只能 on-policy。

CartPole 状态有位置、速度、杆角度、角速度四个连续量。普通精确表需要无限/极大格数，可离散化或函数逼近；普通 DQN 的有限动作输出难以直接处理模拟摇杆连续控制，参数化连续策略是一种替代。

资料里的明确范围标记

Week 10 PDF p49–52 的详细梯度推导标 OPTIONAL；p73 GAN、p74 RNN、p75 Transformer 标 not assessed。保留基本概念即可。这里的优先级来自文件标记与学习目标，不是对真实试卷分值的预测。

原始资料定位

- Week 10 · MC / TD / Approximation / ML，PDF 文件第 54–75 页；lecture/COMP3702_Module-4-2026_Wk10.pdf。

- Week 11 · Deep RL，PDF 文件第 14–35 页；lecture/COMP3702_Module-4-2026_Wk11.pdf。

- Tutorial 9，PDF 文件第 2–3 页；APP/COMP3702_Tutorial_9(1).pdf。

掌握检验

□ 解释 DQN 输入输出、target、loss 和终止掩码

□ 解释 replay / target network 各自解决的问题

□ 比较值方法与直接策略方法

12 • 极小极大与 α–β 剪枝 / Adversarial search

前提与 backup

两人、零和、交替行动、完全信息时，从 MAX 的统一效用视角分析：

```
V(s)=U(s)                    终止
V(s)=max_child V(child)      MAX 节点
V(s)=min_child V(child)      MIN 节点
```

深度截断时用 evaluation function e(s) 代替终局效用；它是估计，不保证真实胜负。常用特征线性组合，但要说明正负方向统一为 MAX 的利益。

α–β：当前分支无法改变根选择时剪枝

MAX 已有 3；MIN 一旦看到 2，该子树只可能 ≤2，无法胜过 3。



B 的已知上界是 2；其真实值为 1，但求根决策不必知道它。

α 与 β

α 是沿祖先路径 MAX 已能保证的下界；β 是 MIN 已能保证的上界。根调用从 (−∞,+∞) 开始。深度优先遍历，MAX 更新 α=max(α,v)，MIN 更新 β=min(β,v)。当 α≥β 时，当前剩余兄弟分支无需再查。

```
def alphabeta(node, alpha, beta, is_max):
    if terminal(node):
        return utility(node)
    value = -inf if is_max else inf
    for child in ordered_children(node):
        score = alphabeta(child, alpha, beta, not is_max)
        value = max(value, score) if is_max else min(value, score)
        if is_max:
            alpha = max(alpha, value)
        else:
            beta = min(beta, value)
        if alpha >= beta:
            break
    return value
```

从左到右完整例题

根 MAX 有 A、B、C 三个 MIN 子节点；叶值 A=[3,5,6]，B=[2,9,1]，C=[4,7,8]。

1. A 全部检查得 min=3，根 α=3。

2. B 首叶 2，使 β=2≤α=3；B 剩余 9、1 可剪。我们知道 B≤2，已不可能胜过根的 3；剪枝时回传的界不一定是 B 的真实 minimax 值（真实为 1）。

3. C 查 4、7、8 得 4，根更新为 4，选 C。

不剪枝需看 9 个叶子，按该顺序剪枝后看 7 个，根值仍为 4。交互实验显示每个叶子的访问、α/β 变化与被剪分支。

为什么剪掉也不影响根

MAX 已有值≥3 的选择；B 是 MIN 节点，看到一个 2 就知道 B≤2，未看叶值只可能让 B 更低，不可能把 B 抬到 3 以上。因此根不会选 B。不能说“9 一定没用因为很大”，真正依据是祖先界。

复杂度与答题要点

Minimax 时间 O(b□)，深度优先存 frontier 通常 O(bd)。α–β 最坏仍 O(b□)，理想动作排序可接近 O(b^(d/2))；排序改变剪枝数，不改变完整搜索的根 minimax 值。写每个剪枝点的 α≥β 依据，并标明哪些返回值只是 bound。浅层 evaluation 不准时，剪枝仍保持该截断搜索的结果，但不保证真实游戏最优。

原始资料定位

- Week 12 · Module 5 / Game Theory，PDF 文件第 15–39 页；lecture/COMP3702_Module-4-2026_Wk12.pdf。

- Alpha-beta supplementary demo，PDF 文件第 1–41 页；lecture/alpha-beta-pruning.pdf。

- Tutorial 11，PDF 文件第 1 页；APP/COMP3702_Tutorial_11(1).pdf。

掌握检验

□ 手算 minimax 和 α–β 的界、访问顺序、剪枝位置

□ 解释剪枝正确性与动作排序的影响

13 • 优势策略、最佳回应与 Nash 均衡 / Game theory

普通式博弈

行玩家选择行，列玩家选择列，每格 (u_row,u_col)，双方各自最大化自己的效用。零和表若只给行收益，列玩家最小化它。pure strategy 是一个确定选择；mixed strategy 是对纯策略的概率分布；support 是概率大于 0 的动作集。

Dominance 与 Nash

严格支配：无论对手怎么做，策略 A 收益都严格大于 B。弱支配：所有情况下不差，至少一种情况严格更好。dominant strategy 对所有对手策略都是最佳；dominant-strategy equilibrium 中每人都采用占优策略，因此也是 Nash。

Nash：在其他人的策略固定时，任何一人**单方面改变**都不能提高收益。它不保证合作、社会最优或唯一。有限博弈至少存在一个混合策略均衡，但不保证纯策略均衡。

弱支配策略的逐次删除可能依赖顺序，也可能删掉某些 Nash 均衡；如果题目要找全部均衡，不能盲目弱删除后宣称找全。严格被支配的动作不在 Nash 的支持集内。

找纯策略均衡：画最佳回应

给定每列，标行玩家收益最大的位置；给定每行，标列玩家收益最大的位置；同时被两者标记的格子就是 pure NE。把并列最佳全部标上，避免漏解。

例：

行\列	L	R
U	(3,3)	(0,2)
D	(2,0)	(1,1)

列 L 时行选 U，列 R 时行选 D；行 U 时列选 L，行 D 时列选 R。纯均衡为 (U,L)、(D,R)。此外还有完全混合均衡：设 p=P(U)，q=P(L)，令行无差异：3q=2q+1−q □ q=.5；令列无差异：3p=2p+1−p □ p=.5。不能只找完纯均衡就说没有混合均衡。

零和安全水平

行玩家纯策略 maximin=max_rows min_cols u；列玩家纯策略 minimax=min_cols max_rows u。两者相等形成纯策略鞍点；允许混合策略后有限两人零和博弈满足 minimax equality。

完全混合 2×2：让对方无差异

如果行收益矩阵 [[a,b],[c,d]] 为零和，p=P(行1)，q=P(列1)：

```
行无差异：aq+b(1−q)=cq+d(1−q)
列无差异：ap+c(1−p)=bp+d(1−p)
q=(d−b)/(a−b−c+d), p=(d−c)/(a−b−c+d)
```

通式只适用于分母非零且结果在 [0,1] 的内部混合情形；一般和游戏必须分别使用两人的收益矩阵。求的是**对方**使自己无差异的概率，不要把 p、q 交换。

讲义点球题，保留原方向定义

矩阵是进球概率 [[.6,.2],[.3,.9]]；定义 p_k=P(kicker 右)，p_g=P(goalie 右)。守门员要最小化进球概率。

```
goalie 左：.6(1−p_k)+.3p_k=.6−.3p_k
goalie 右：.2(1−p_k)+.9p_k=.2+.7p_k
相等 → p_k=.4
kicker 左：.6(1−p_g)+.2p_g=.6−.4p_g
kicker 右：.3(1−p_g)+.9p_g=.3+.6p_g
相等 → p_g=.3
value=.48
```

在均衡 p_k=.4,p_g=.3 时，任何一方单独换成纯左或纯右都不能改进。交互实验可调概率，查看单方面偏离的收益。

Tutorial 11 Morra 的检查方法

策略为 (展示手指,猜总数)。猜中则对方支付总数；都猜中或都没猜中则净转移 0。展示 1 却猜 4、展示 2 却猜 2 不可能猜中，是应先检查的弱被支配动作。写出矩阵时用 u(A,B)=total×[A猜中−B猜中]，两人的净收益互为相反数。

对称零和均衡价值为 0。题中候选混合：以 .6 选 (1,3)、.4 选 (2,3)。对手可选 (2,4)，收益 .6×(−3)+.4×4=−.2；这不构成获利偏离。还需逐个检验所有其他纯动作；本包题解给出 (1,2) 收益 .6×2+.4×(−3)=0、(1,3) 收益0、(2,3)收益0、(2,4)收益−.2，其余不可猜中的动作不改进，因此该候选确实是一个对称 NE（双方均用该混合）。不能只检查一个偏离或只凭“随机”就判均衡。

原始资料定位

- Week 12 · Module 5 / Game Theory，PDF 文件第 41–66 页；lecture/COMP3702_Module-4-2026_Wk12.pdf。

- Tutorial 11，PDF 文件第 2 页；APP/COMP3702_Tutorial_11(1).pdf。

掌握检验

□ 标记纯策略最佳回应并检验 dominance/DSE/NE

□ 用无差异条件求混合均衡并检查支持集

□ 写出零和 maximin 并逐项验证偏离收益

14 • Responsible AI 简答题 / Human-centred & responsible AI

课程框架

Responsible AI 将开发、部署、使用和影响纳入责任范围。Human-centred AI 强调人的需求与体验；ethical AI 强调避免伤害与道德行为；算法偏差可能来自历史不平等、样本覆盖、代理标签、目标函数和部署反馈。

五步答题框架

1. **Understand people’ s needs**：识别使用者和受影响者，理解具体需要、能力、自主性与关系。

2. **Co-design / participatory design**：让目标群体在问题定义、原型、测试和改进中参与，不能仅由开发者替其决定。

3. **Measure impact**：同时评估系统表现、个体福祉、社会影响和群体差异。点击率/参与度高不等于对人有益。

4. **Ethics**：将公平、隐私与安全、人本价值、福祉、透明可解释、可靠安全、可争议与问责转化为具体设计和评估。

5. **Trust**：用真实可靠性、说明限制、审查与治理展示值得信任；增加界面亲切感不能替代可信赖的系统。

讲义案例：医疗资源分配

用既往医疗花费预测医疗需求，会把“某群体长期获得医疗资源少”的现象误当成“该群体需要少”。总体预测看起来准确也可能强化不平等。

高质量答案的因果链：**不当代理标签 → 系统性低估需求 → 资源分配不足 → 更差的实际健康结果。**改进：采用更直接的需求指标，与受影响者和专业人员共同验证，分群评估误差和分配结果，设置人工复核与申诉，并持续监测。

讲义案例：失智老人支持系统

仅假设用户需要“对话时提示单词”可能使产品不被使用。共同设计能发现更贴合用户的需求；应验证可接受性、尊严、自主性、照护者负担与实际效益，不能只报告识词准确率。

可迁移答题模板

“本情境中，[群体] 可能因 [数据/标签/目标/部署机制] 受到 [具体伤害]。开发前通过 [参与式方法] 核实需求；设计上采用 [具体措施]；以 [分群指标+福祉指标] 评价；部署后通过 [责任主体、复核、申诉、监测] 持续改进。”

例：招聘 AI 的代理标签若来自过去录用者，可能复制历史偏差。应审查标签和覆盖，与求职者及招聘人员共同设计，检验不同群体的错误拒绝率和可访问性，为受影响者提供解释、复核与申诉渠道。不要只写“数据更多” “提高透明度”而不说明如何减少本例伤害。

本章按提供的 Responsible_AI.pdf 整理课堂概念；不是对最新法律或监管义务的说明。

原始资料定位

- Responsible AI，PDF 文件第 5–32 页；lecture/Responsible_AI.pdf。

掌握检验

□ 用具体因果链分析偏差与伤害

□ 按人类需求、共创、影响、伦理、信任提出可执行措施

15 • 命题逻辑补充与资料缺口 / Supplementary logic & scope

为什么单列补充

Module 0 的周计划列出了 Propositions / Inference / CNF / satisfiability & verification，但提供的 Module 2 讲义正文和 Tutorial 4 主要是 CSP，没有找到独立逻辑讲义。以下是为防遗漏而加入的基础补充，**不能据此确认逻辑一定在最终考试范围内。**拿到教师 revision slides 或样卷后，应优先校准。

语法与语义

p,q 是命题，¬、∧、∨、→、□ 为连接词。model 是使公式为真的赋值。satisfiable 表示至少一个 model，valid 表示所有赋值都为真，unsatisfiable 表示无 model。蕴涵 KB □ α 表示每个满足 KB 的赋值都满足 α；不同于“我暂时没找到反例”。

```
p→q ≡ ¬p∨q
p□q ≡ (¬p∨q)∧(¬q∨p)
¬(p∧q) ≡ ¬p∨¬q
¬(p∨q) ≡ ¬p∧¬q
KB□α □ KB∧¬α 不可满足
```

Sound inference 不推出不被语义支持的结论；complete inference 可以推出所有被语义蕴涵的结论。它们与搜索的“完备性”共享英文词，但具体定义不能混为一谈。

CNF

CNF 是若干子句的合取，每个子句是文字的析取，文字为命题或其否定。转换流程：消去 □、→；把否定推到原子命题；将 ∨ 对 ∧ 分配；整理子句。

例：p→(q∧r) ≡ ¬p∨(q∧r) ≡ (¬p∨q)∧(¬p∨r)。不要误写成 (¬p∧q)∨r。

Resolution

由 (p∨A) 和 (¬p∨B) 可推出 (A∨B)。例：KB={p→q,p}，问是否蕴涵 q：子句 {¬p∨q,p,¬q}；先由前两句得 q，再与 ¬q 消解得空子句 □，故 KB □ q。

有 2^n 个命题赋值，穷举验证指数增长。SAT 与 CSP 都是在找满足约束的赋值，但一般 SAT 变量为布尔、公式通常子句表示；CSP 可有更一般的域和约束。

考前需要补齐的资料

最新 revision/考试公告、官方 practice exam 与评分说明、可能独立发布的逻辑讲义、当前文件中缺少的 Tutorial 10 或其他补充课内容。这里的两套模拟卷是自编训练卷，时间和分值是练习设置，不是官方考试规则。

原始资料定位

- Module 0 · Introduction，PDF 文件第 10 页；lecture/COMP3702_Module-0_IntroToAI.pdf。

掌握检验

□ 在范围确认后复习 CNF、蕴涵、SAT 与简单消解

□ 识别当前资料没有确认的考试信息

COMP3702 公式与易错点速查

与复习主册配套。所有题先声明奖励时点、索引、tie-break 和更新顺序。

主题	公式/规则	一秒检查
UCS / GBFS / A*	f=g / h / g+h	最小 f 优先；UCS/A* 目标通常出队判断
Admissible	0≤h≤h*	不高估剩余成本
Consistent	h(n)≤c(n,n′)+h(n′)	每条有向边都要检验
8-puzzle	起点 parity=目标 parity	3×3 忽略空格算逆序
CSP 弧	□x∈D(X),□y∈D(Y):C(x,y)	删 X 后重查 Z→X
AC-3	O(ed³)	AC 后多值不能判有解
Bayes	P(H∣E)=P(E∣H)P(H)/P(E)	分母要含所有原因
Markov chain	x□□□=x□P；xP=x	行是当前、列是下一

主题	公式/规则	一秒检查
MEU	argmax□Σ□P(o∣a)U(o)	E[U(X)]≠U(E[X])
Return	G□=R□□□+γG□□□	第一笔奖励不打折
Constant reward	r/(1−γ)	需 γ<1
Bellman Q	Σ□′T(s,a,s′)[R+γV(s′)]	先结果求和，再动作 max
Optimal V / policy	max□Q / argmax□Q	max 是值；argmax 是动作
Policy evaluation	(I−γPπ)Vπ=rπ	固定策略，无 max
VI	V□□□=TV□	同步时全用旧值
VI residual	∥V□□□−V*∥≤γΔ/(1−γ)	Δ=新旧两轮 sup 差
MCTS mean	Qnew=Qold+(G−Qold)/Nnew	计数先从旧值+1
UCT	Q□+c√(lnN/n)	未试动作先试
ε-greedy	唯一 best：1−ε+ε/k	探索也可能抽到 best
Softmax	exp(Q/τ)/Σexp(Q/τ)	τ 大更均匀
UCB tutorial	Q+√(C lnN/n)	讲义 C 在根号外，别照抄数值
MC	V←V+α(G−V)	等实际回报，无 bootstrap
TD(0)	V←V+α(r+γV′−V)	bootstrap 下一状态
Q-learning	Q←Q+α(r+γmaxQ′−Q)	off-policy；不管实际 a′
SARSA	Q←Q+α(r+γQ(s′,a′)−Q)	on-policy；使用实际 a′
Terminal	target=r	只终止后继未来值为0
Linear Q	Q=w·f；w□←w□+αδf□	同一次 δ 用旧权重
DQN	y=r+γ(1−done)maxQ_target；L=mean(y−Q)²	replay 去相关；target 稳定目标
Minimax	MAX=max，MIN=min	统一 MAX 效用视角
α–β	α≥β 剪枝	剪枝子树的返回值可能只是界
Nash	无人能单方面获益偏离	不保证社会最优
Mixed NE	让对手支持集中动作无差异	还要检查支持集外动作
AND-OR	OR 至少一个；AND 全部	条件计划含环境所有分支
Responsible AI	需求→共创→影响→伦理→信任	每个措施对准具体伤害

常见数值锚点

搜索实验：BFS 11、DFS 7、UCS/A* 6、GBFS 8。Bayes 算例 4/13。MDP backup 5.18。Q-learning/SARSA 对照 6.1/2.95。Pacman 权重 2.998/−3.004。点球 p_right=.4,q_right=.3,value=.48。记住的是计算方法，数字仅用于核对本包特定例子。

考场流程

先读清“最小成本/最大效用”“确定/随机/对手”“已知模型/只有样本”；建立模型；写公式；列中间表；代入计算；解释结果；最后检查概率和、符号、终止状态、折扣次数、可用动作。